


Métodos de Diferença temporal (TD)

O que são

- Base para a maioria dos métodos avançados de RL:
 - Tentativa e erro do MMC: aprende por experiência
 - Amostragem da PD: estimativas de valores $Q(s, a)$
 - Memória

O que são



O que são

Comparação

- Métodos de Monte-Carlo esperam até o fim de um episódio para calcular G_t e atualizar $Q(s, a)$

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T$$

- Métodos de TD atualizam $Q(s, a)$ toda vez que um agente realiza uma ação

Alicerce de um Método de TD

- Como nos outros métodos, uma tabela de valores $q(s, a)$ é construída para cada par S_t, A_t

$$q_{\pi}(s, a) = \mathbb{E}[G_t | S_t = s, A_t = a] \quad q_{\pi}(s, a) = \sum_{s', r} p(s', r | s, a) [r + \gamma v_{\pi}(s')]$$

$$q_{\pi}(s, a) = \sum_{s', r} p(s', r | s, a) [r + \gamma \sum_{a'} \pi(a' | s') q_{\pi}(s', a')]$$

Alicerce de um Método de TD

$$q_{\pi}(s, a) = \sum_{s', r} \underbrace{p(s', r | s, a)}_{\substack{\text{red arrow to } R_{t+1} \\ \text{red arrow to } S_{t+1}}} [r + \gamma \underbrace{\sum_{a'} \pi(a' | s') \underbrace{q_{\pi}(s', a')}_{\substack{\text{blue arrow to } Q}}]}_{\substack{\text{red arrow to } A_{t+1}}}]$$

Alicerce de um Método de TD

- $Q_{\pi}(S_t, A_t)$ podem ser estimados por:

$$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$$

$$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)$$



Erro de Diferença temporal

Alicerce de um Método de TD

- Diferentes métodos possuem diferentes estimativas de $Q(S_t, A_t)$

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

Lembre-se do Método de Monte-Carlo com α constante

Alicerce de um Método de TD

- Reorganizando:

$$Q(S_t, A_t) \leftarrow (1 - \alpha)Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

SARSA

Primeiro algoritmo de TD

- SARSA: $S_t, A_t, R_t, S_{t+1}, A_{t+1}$

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

- O SARSA é *on-policy*, só tem uma política
- Como no MMC, usa a política ϵ -gulosa para exploração

SARSA

Primeiro algoritmo de TD

Algorithm 1 SARSA

```
1: Input:  $\alpha$  learning rate,  $\epsilon$  random action probability,  $\gamma$  discount factor
2:  $\pi \leftarrow \epsilon$ -greedy policy w.r.t  $Q(s, a)$ 
3: Initialize  $Q(s, a)$  arbitrarily, with  $Q(\text{terminal}, \cdot) = 0$ 
4: for episode  $\in 1..N$  do
5:   Reset the environment and observe  $S_0$ 
6:    $A_0 \sim \pi(S_0)$ 
7:   for  $t \in 0..T - 1$  do
8:     Execute  $A_t$  in the environment and observe  $S_{t+1}, R_{t+1}$ 
9:      $A_{t+1} \sim \pi(S_{t+1})$ 
10:     $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$ 
11:  end for
12: end for
13: Output: Near optimal policy  $\pi$  and action values  $Q(s, a)$ 
```

SARSA

Primeiro algoritmo de TD

Abra o Notebook SARSA.ipynb

Q-Learning

Segundo Algoritmo de TD

- O Q-Learning é *off-policy*, possui uma politica exploratória π_b
- Funciona exatamente como o SARSA, mas usa π_b para gerar uma trajetória

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

$$A_{t+1} = \pi(S_{t+1}) = \operatorname{argmax}_a Q(S_{t+1}, a)$$

Q-Learning

Segundo Algoritmo de TD

Algorithm 2 Q-Learning

```
1: Input:  $\alpha$  learning rate,  $\gamma$  discount factor
2:  $\pi \leftarrow$  greedy policy w.r.t  $Q(s, a)$ 
3:  $b \leftarrow$  exploratory policy with coverage of  $\pi$ 
4: Initialize  $Q(s, a)$  arbitrarily, with  $Q(\text{terminal}, \cdot) = 0$ 
5: for episode  $\in 1..N$  do
6:   Reset the environment and observe  $S_0$ 
7:   for  $t \in 0..T - 1$  do
8:      $A_t \sim b(S_t)$ 
9:     Execute  $A_t$  in the environment and observe  $S_{t+1}, R_{t+1}$ 
10:     $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \pi(S_{t+1}) - Q(S_t, A_t)]$ 
11:   end for
12: end for
13: Output: Approximately optimal policy  $\pi$  and action values  $Q(s, a)$ 
```

Q-Learning

Segundo algoritmo de TD

Abra o Notebook QLearning.ipynb

Métodos de ***n***-passos

Generalização de Métodos de TD

- Regra de atualização do SARSA

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

- *Bootstrapping* de 1 passo (1-step)

$$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$$

Métodos de ***n***-passos

Generalização de Métodos de TD

- *Bootstrapping* de 2 passos (2-step)

$$R_{t+1} + \gamma R_{t+2} + \gamma^2 Q(S_{t+2}, A_{t+2})$$

- *Bootstrapping* de 3 passos (3-step)

$$R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 Q(S_{t+3}, A_{t+3})$$

- *Bootstrapping* de n passos (n-step)

$$R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n Q(S_{t+n}, A_{t+n})$$

Retorno de *n*-passos

- Estimativa de *n*-retornos

$$G_{t:t+n} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n Q(S_{t+n}, A_{t+n})$$

SARSA *n*-passos

- SARSA é apenas um caso especial de *1-step bootstrapping*

$$G_{t:t+n} = R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$$

$$Q(S_t, A_t) \rightarrow Q(S_t, A_t) + \alpha [G_{t:t+n} - Q(S_t, A_t)]$$

Retorno de *n*-passos

$$G_{t:t+2} = R_{t+1} + \gamma R_{t+2} + \gamma^2 Q(S_{t+2}, A_{t+2})$$

$$G_{t:t+3} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 Q(S_{t+3}, A_{t+3})$$

...

Se $n \geq T$:

$$G_{t:t+n} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} \quad \text{Monte-Carlo}$$

$$Q(S_t, A_t) \rightarrow Q(S_t, A_t) + \alpha [G_{t:t+n} - Q(S_t, A_t)]$$

Generalização de algoritmos de *n*-passos

$G_{t:t+1}$

$G_{t:t+n}$

TD

Monte-Carlo



Generalização de algoritmos de n -passos

- Para que serve os valores de n ?
- Regulagem do **viés (*bias*)** e da **variância (*variance*)**



Generalização de algoritmos de n -passos

- Viés (*bias*)



Generalização de algoritmos de n -passos

- Variância (*variance*)



Generalização de algoritmos de *n*-passos

- Quanto maior *n* menor o **viés**
- Quanto maior *n* maior a **variância**

$$G_{t:t+2} = R_{t+1} + \gamma R_{t+2} + \gamma^2 Q(S_{t+2}, A_{t+2})$$

$$G_{t:t+3} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 Q(S_{t+3}, A_{t+3})$$

$$G_{t:t+n} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n}$$

SARSA *n*-passos

- Combina-se o SARSA com o *n-step bootstrapping*
- *On-Policy* com politica ϵ -gulosa

$$Q(S_t, A_t) \rightarrow Q(S_t, A_t) + \alpha[G_{t:t+n} - Q(S_t, A_t)]$$

$$G_{t:t+n} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n Q(S_{t+1}, A_{t+1})$$

SARSA n -passos

Algorithm 1 n -step SARSA

```
1: Input:  $\alpha$  learning rate,  $\epsilon$  random action probability,  
2:    $\gamma$  discount factor,  $n$  bootstrap timestep  
3:  $\pi \leftarrow \epsilon$ -greedy policy w.r.t  $Q(s, a)$   
4: Initialize  $Q(s, a)$  arbitrarily, with  $Q(\text{terminal}, \cdot) = 0$   
5: for episode  $\in 1..N$  do  
6:   Reset the environment and observe  $S_0$   
7:    $A_0 \sim \pi(S_0)$   
8:   while  $t - n < T$  do  
9:     if  $t < T$  then  
10:      Take action  $A_t$  and observe  $R_{t+1}, S_{t+1}$   
11:       $A_{t+1} \sim \pi(S_{t+1})$   
12:    end if  
13:    if  $t \geq n$  then  
14:       $B = Q(S_{t+1}, A_{t+1})$  if  $t + 1 < T$ , else 0  
15:       $G = R_{t-n+1} + \gamma R_{t-n+2} + \dots + \gamma^{n-1} R_{t+1} + \gamma^n B$   
16:       $Q(S_{t-n}, A_{t-n}) \leftarrow Q(S_{t-n}, A_{t-n}) + \alpha [G - Q(S_{t-n}, A_{t-n})]$   
17:    end if  
18:  end while  
19: end for  
20: Output: Near optimal policy  $\pi$  and action values  $Q(s, a)$ 
```

N-Step SARSA

Terceiro algoritmo de TD

Abra o Notebook NStepSARSA.ipynb